

GCI Winter 2024 最終課題

リクルート社Airレジ^{*1}様に対する事業提案

Koshi Harashima, 2024/01/23

*1 Airレジに表記を統一した

エグゼクティブサマリー

問い合わせの回数を予測する機械学習モデルを作成し、
コールセンターの人員の適切な配置を可能にする。

市場

無料タブレットPOS業界は年々激化

■消費税の増税と軽減税率の導入、キャッシュレスの促進といった政策によって、レジPOS業界の競争は年々激化している。既存のハードウェアを用いたPOSレジに加えて、ソフトウェアを提供する会社が複数参入している。

課題

御社の課題は顧客の対応が不十分であること。

■無料であるが故にアカウントを離れる人が多い。
■顧客へのサービスとして、問い合わせの対応をしている。アカウントが多い分、以前から顧客対応に苦慮していた。顧客満足度向上のためにはより問い合わせへの対応を改善することが今後必須である。

モデリング

時系列解析「VAR」と機械学習「XGBoost」を用いた問い合わせ回数の予測

■検索数やアカウント数、広告の有無のデータに基づいて、問い合わせの回数を予測する機械学習モデルの作成の方法を提案し、実際に作成した。

提案

コールセンターの人員の適切な配置提案し、コスト削減へ


■予測値に基づいて、正社員とパートの二種類の労働力によって、コールセンターの適切な人員配置を目指す。実務に耐えうるように1ヶ月単位の予測を行い、削減コストの試算を出した。的確な予測によって、繁忙期(10月)ごろには100万円/月程のコスト削減が見込める。

Airレジを取り巻く市場環境(2018年時点)

小規模店向けにタブレットPCを活用したクラウドベースのPOS サービスが急速に拡大している。タブレットPOS 市場の大枠でのターゲットは、低コストでかつ高性能なレジ業務を簡単に活用しようというユーザー層である。

- ▣ 個店に加えて、飲食店、小売店(アパレル系など)、雑貨店、美容院など。
- ▣ 「Airレジ」が市場を牽引しており、スマレジ、ユビレジも実績を拡大している。
- ▣ 市場全体が今後急速に成長することが予想される(図1参照)。

図1*1 タブレットPOS国内市場規模予測



今後の成長率の要因

[法律・政策要因]

- ▣ 2019年10月に予定される消費税導入があり、更に導入時には軽減税率の適用によるリプレイス需要がある。これらのサービスは軽減税率対応の補助金を受ける対象となっている(駆け込み需要等)。

[その他要因]

- ▣ 新規出店、新規導入での導入の無料化、低減化、
- ▣ 省スペース性、デザイン性
- ▣ 海外旅行客の堅調な増加に伴う観光客への言語対応

競合他社との差別化とビジネスモデル

Airレジの基本サービスは販売記録の保存や売上の分析を行うことである。このサービスを顧客のデータと引き換えにして無償でサービスを提供する。

- 基本サービスは競合他社と似ているが、カスタマイズ性に特化していない。
- 競合他社と同様に、Airペイなど**有料オプション**を多数持っている。
- 広告、求人といったリクルート関連業種**との連携や**営業網**によってサービスの**差別化**を実現
- 結果として**無料**という価格設定を実現し、**アカウント数が最も多い**。

収益源

- 競合他社と同様に、決済、電子請求書発行、経営支援、勤怠管理やシフトの調整等の機能をもつ**有料サービス**を提供しており、それらの月額使用料も収益に入る。
- 特に自社が持つ「Airペイ」では多様な決済サービスを一つのアプリのみで決済することを可能にする代わりに、決済手数料を2~3%ほどがかかる。

Airレジの差別化

- ホットペッパービューティ(飲食店)やホットペッパーグルメ(散髪や美容室)といった規模が拡大している*1プラットフォームを持っている。また、それに付随したリクルート社の営業力とその営業網。
 - 広告、求人といったリクルートの関連サービスとの提携によるマネタイズだ。広告、求人といったリクルートの関連サービスとの提携では、ホットペッパーグルメや転職事業といったリクルート内の他の業種との連携によって収益を確保する。
- =>**アカウント数が最も大きく、独自の収益源による価格設定が可能**

競合他社のサービスと比較

- ビジネスモデルはどのサービスも似ている。
- Airのレジビジネスモデルは基本無料によって差別化をしている**。
- 顧客は棲み分けは多少あるがかなり競争が激しい。

表1*2

POSレジ	主な顧客	ビジネスモデル
Airレジ	小規模店舗・個人事業主	基本無料、周辺サービスで収益化
スマレジ	中小規模店舗・チェーン店	サブスク+決済手数料
ユビレジ	飲食店・小売店	サブスク+決済手数料
Square	小規模店舗・個人事業主	基本無料、決済手数料
USENレジ	飲食店・中規模以上の店舗	サブスク+ハードウェア販売+決済

*1引用10, 11よりどちらも減少や停滞の傾向にないことがわかる。

*2引用4より筆者作成

データから見るAirレジの課題(1)

競合他社も含めた検索数を見ると、どれも法律の施行前後で軒並み一時的な上昇があり、その後は沈静化するという傾向にある。

- 利用する経営者側には比較検討する方が一定数いると考えられる。
- その中でも、無料を標榜していたSquareとAirレジに検索が集まった。
- 2019年10月前後で検索数が伸びる会社と伸びとどまる会社で分かれていく。
- 特に、スマレジやUSENレジ(有料)が着実に伸びる一方、ユビレジは低下していく。
- 検索数には個別の施策の影響が現れているかは分かりづらい。


[考察]

スマレジ、USENレジ
(有料)がうまくいっていることが予測される*1

データの概要

図2・・・
各ブランドの検索数の推移
(Google Trendを元に作成)
検索ワードは、各ブランド
名のみとした。Google
Trendをもとに筆者が作成。
検索ワードは”Airレ
ジ”(青)、“Squareレ
ジ”(黄)、“スマレジ”(赤)、“
ユビレジ”(紫)、“Uレ
ジ”(緑)。“Uレジは呼称で、
USENレジが公式の名前。

図2



*1実際にスマレジはその後着実にカスタマイズに特化させて、顧客を増やしている。

データから見るAirレジの課題(2)

- 競合他社、特に**スマレジ**、**USENレジ**(有料)と比べて、どのような点に課題があるのか。
- その中でもAirレジの幹部自身が課題として挙げていた^{*1}、カスタマーサービスや顧客対応の向上に焦点を当てたい。
 - 例えば、スマレジはカスタマイズ性を通して、便利さをアプローチしている。USENレジもいつでも訪問してくれるという安心を売りにしている。
 - AirレジはUSEN^{*3}やヤマダ電機等と連携をして顧客対応を図っている。

表2^{*2}

サービス名	設置支援	訪問設置	無料プラン	サポート体制	主なデメリット
Airレジ	簡単なセットアップ	なし	あり	メール・チャット（電話なし）	訪問サポートなし
スマレジ	オンライン相談・ショールームあり	あり（有料）	あり	メール・チャット・電話（有料プラン）	無料プランは機能制限あり
ユビレジ	オンラインガイドあり	なし	なし	電話（有料プラン）	無料プランなし
Square	簡単に導入可能	なし	あり	メール・電話（時間制限あり）	訪問サポートなし
USENレジ	訪問設置あり（有料）	あり	なし	24時間365日（有料）	月額料金が高め

Airレジの課題

- アプリの利用が無料であり、アカウント数が多いため、顧客への個別対応が難しい現状がある。
- USENとの提携やヤマダ電機等での設置・修理や質問の受け答えの委託等に頼っている部分がある。
- 競合他社に比べて依然としてサポート体制や問い合わせ体制は低いレベルである(表2参照)。

^{*1}引用9より
^{*2}表2は引用3を元に作成
^{*3}引用2より筆者作成

データから見るAirレジの課題(3)

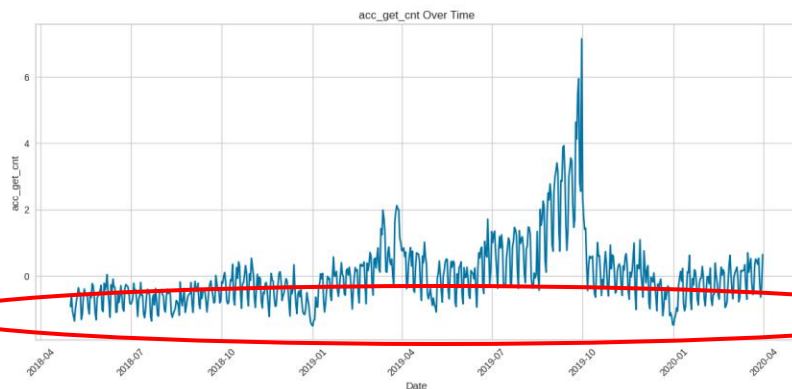
カスタマーサービスや顧客対応が**アカウントの定着率が悪いこと**の原因と考えられる(図3参照)。

- カスタマーサービスや顧客対応の一つである問い合わせについて考える。
- 軽減税率対応補助金の申請期限での駆け込みの際に大量の問い合わせが来ている(図4参照)。
- 通常の問い合わせとこの急激な問い合わせの増加の両方に対応することで、収益増加につながる。よって、コールセンターの人員を的確に確保することが重要である。
- 表3のように、問い合わせに丁寧な対応をすることによって定着する可能性がある場合はした方が良い
- しかし、**コールセンターの増員は費用が嵩む**。=>そこで**機械学習による予測で最適な人員配置**をする。

図3 アカウント獲得数の推移*1

[考察]

マイナス部分が多い。
無料なので、定着しづら
いのではないか。



[考察]

この増減を予測する
ことができれば良い

図4 問い合わせの数の推移



表3

	丁寧な対応をす る	丁寧な対応を しない
定着する	施策をするべき	何もしなくても 良い
定着しない	何もしなくても 良い	施策をするべき

*1図3, 4,は提供されたデータを週ごとに集計して表示

データから見るAirレジの課題(4) データの相互関係を調べてみると、

図3 アカウント獲得数の推移 *1




図5 検索数の推移 *1


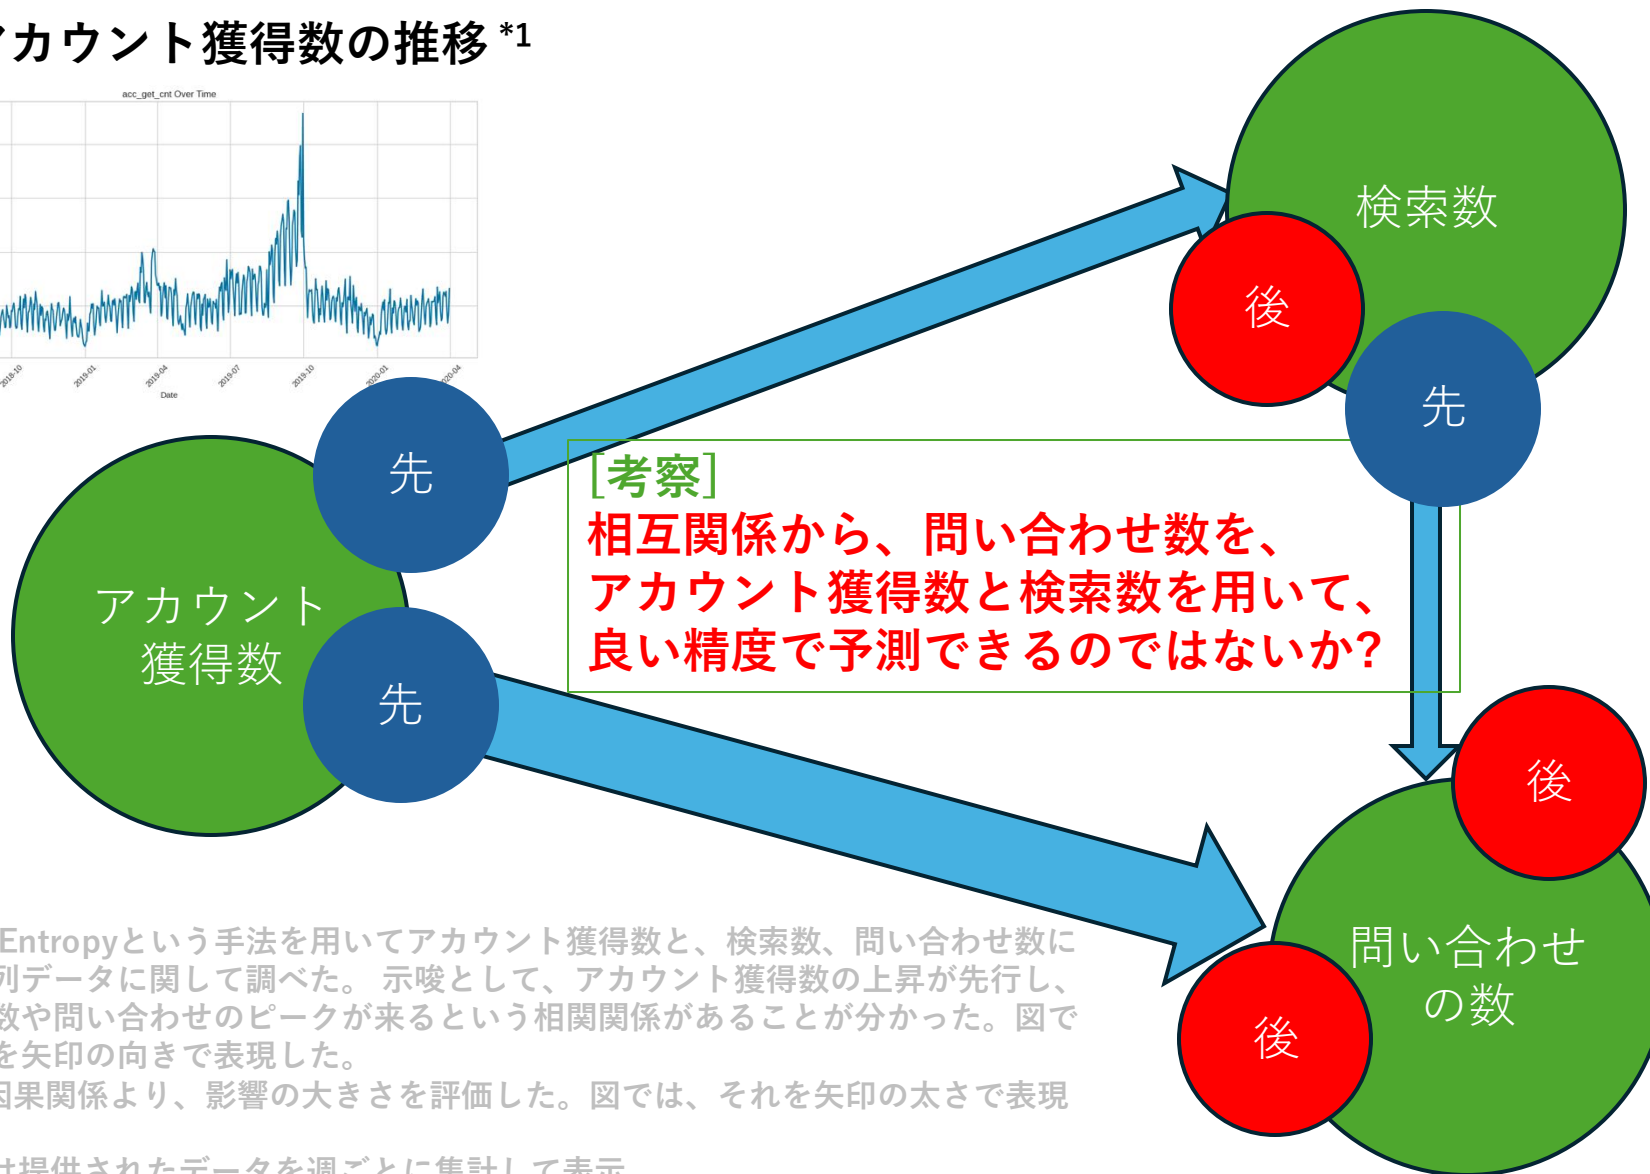



図4 問い合わせの数の推移 *1



■Transfer Entropyという手法を用いてアカウント獲得数と、検索数、問い合わせ数に関する時系列データに関して調べた。示唆として、アカウント獲得数の上昇が先行し、その後検索数や問い合わせのピークが来るという相関関係があることが分かった。図では先行関係を矢印の向きで表現した。

■Granger因果関係より、影響の大きさを評価した。図では、それを矢印の太さで表現した。

*1図3, 4, 5は提供されたデータを週ごとに集計して表示

ご提案

問い合わせの回数を予測する機械学習モデルを作成し、コールセンターの人員の適切な配置を可能にする。



Problem

■アカウントの定着率が低いのが競合他社に比べて**顧客への対応** (問い合わせの対応)の満足度が低い事に起因すると考えられる。




Insight

■相関関係を調べてみれば、**問い合わせの急激な増減**は、アカウント獲得数や広告の有無、検索数といった定量的な視点で**予測可能**でありそうだ。



Modeling

■データを用いて、時系列解析モデルの**VAR**と機械学習モデルである**Xgboost**を組み合わせて、問い合わせ数を予測するモデルを作成する。



Solution

■1ヶ月単位で問い合わせ数の予測を出し、適切な人員配置によって、コスト削減をしながら、顧客への対応の向上を目指す。

モデルの説明 -モデル編-

時系列解析VARと機械学習モデルXGBoostを組み合わせたモデルで御社の事業に**適した**機械学習モデルを制作した。

- VARは、複数の特徴量からそれらの未来の値を予測することが得意である。
- しかし、VARでは時系列から特徴量(検索数、アカウント獲得数、問い合わせ数)を予測することは、できるが、**相互の捉えづらい関係(非線形)やドメイン知識**を捉えきれない。
- XGBoostは同じ時点の複数の特徴量からある値を高精度で予測することが得意である。
- 組み合わせることで**VARの限界をXGBoostが補完することになる。**

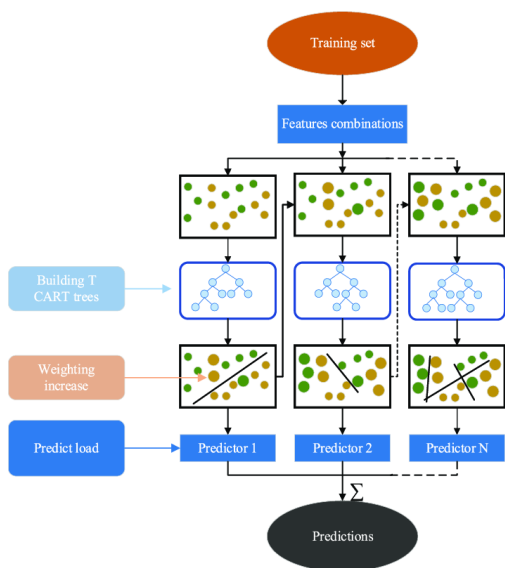


図6 XGBoostの構造*3

XGBoostとは*1

- XGBoostで**非線形な関係を学習し、より高精度な未来予測を行う。**
 - ・ 機械学習における勾配ブースティング (Gradient Boosting) のアルゴリズムを効率的(実行が早い)に拡張した手法です。
- ブースティングは、弱い学習器 (通常は決定木) を多数組み合わせ、予測精度を向上させるものだ。
- Kaggleや競技プログラミングで多く採用されている。

VARとは*2

- **経済・金融データ、マクロ経済分析**に広く使用されている。VAR (ベクトル自己回帰) モデルは、各変数が過去の自分自身の値 (自己回帰) だけでなく、他の変数の過去の値にも影響を受ける という特徴を持つ。因果関係の推定も簡単にできる(解釈がしやすい)。
- 今回の検索数とアカウント獲得数と問い合わせの数は(経済データのように)相互関係があり、適していると考えれる。


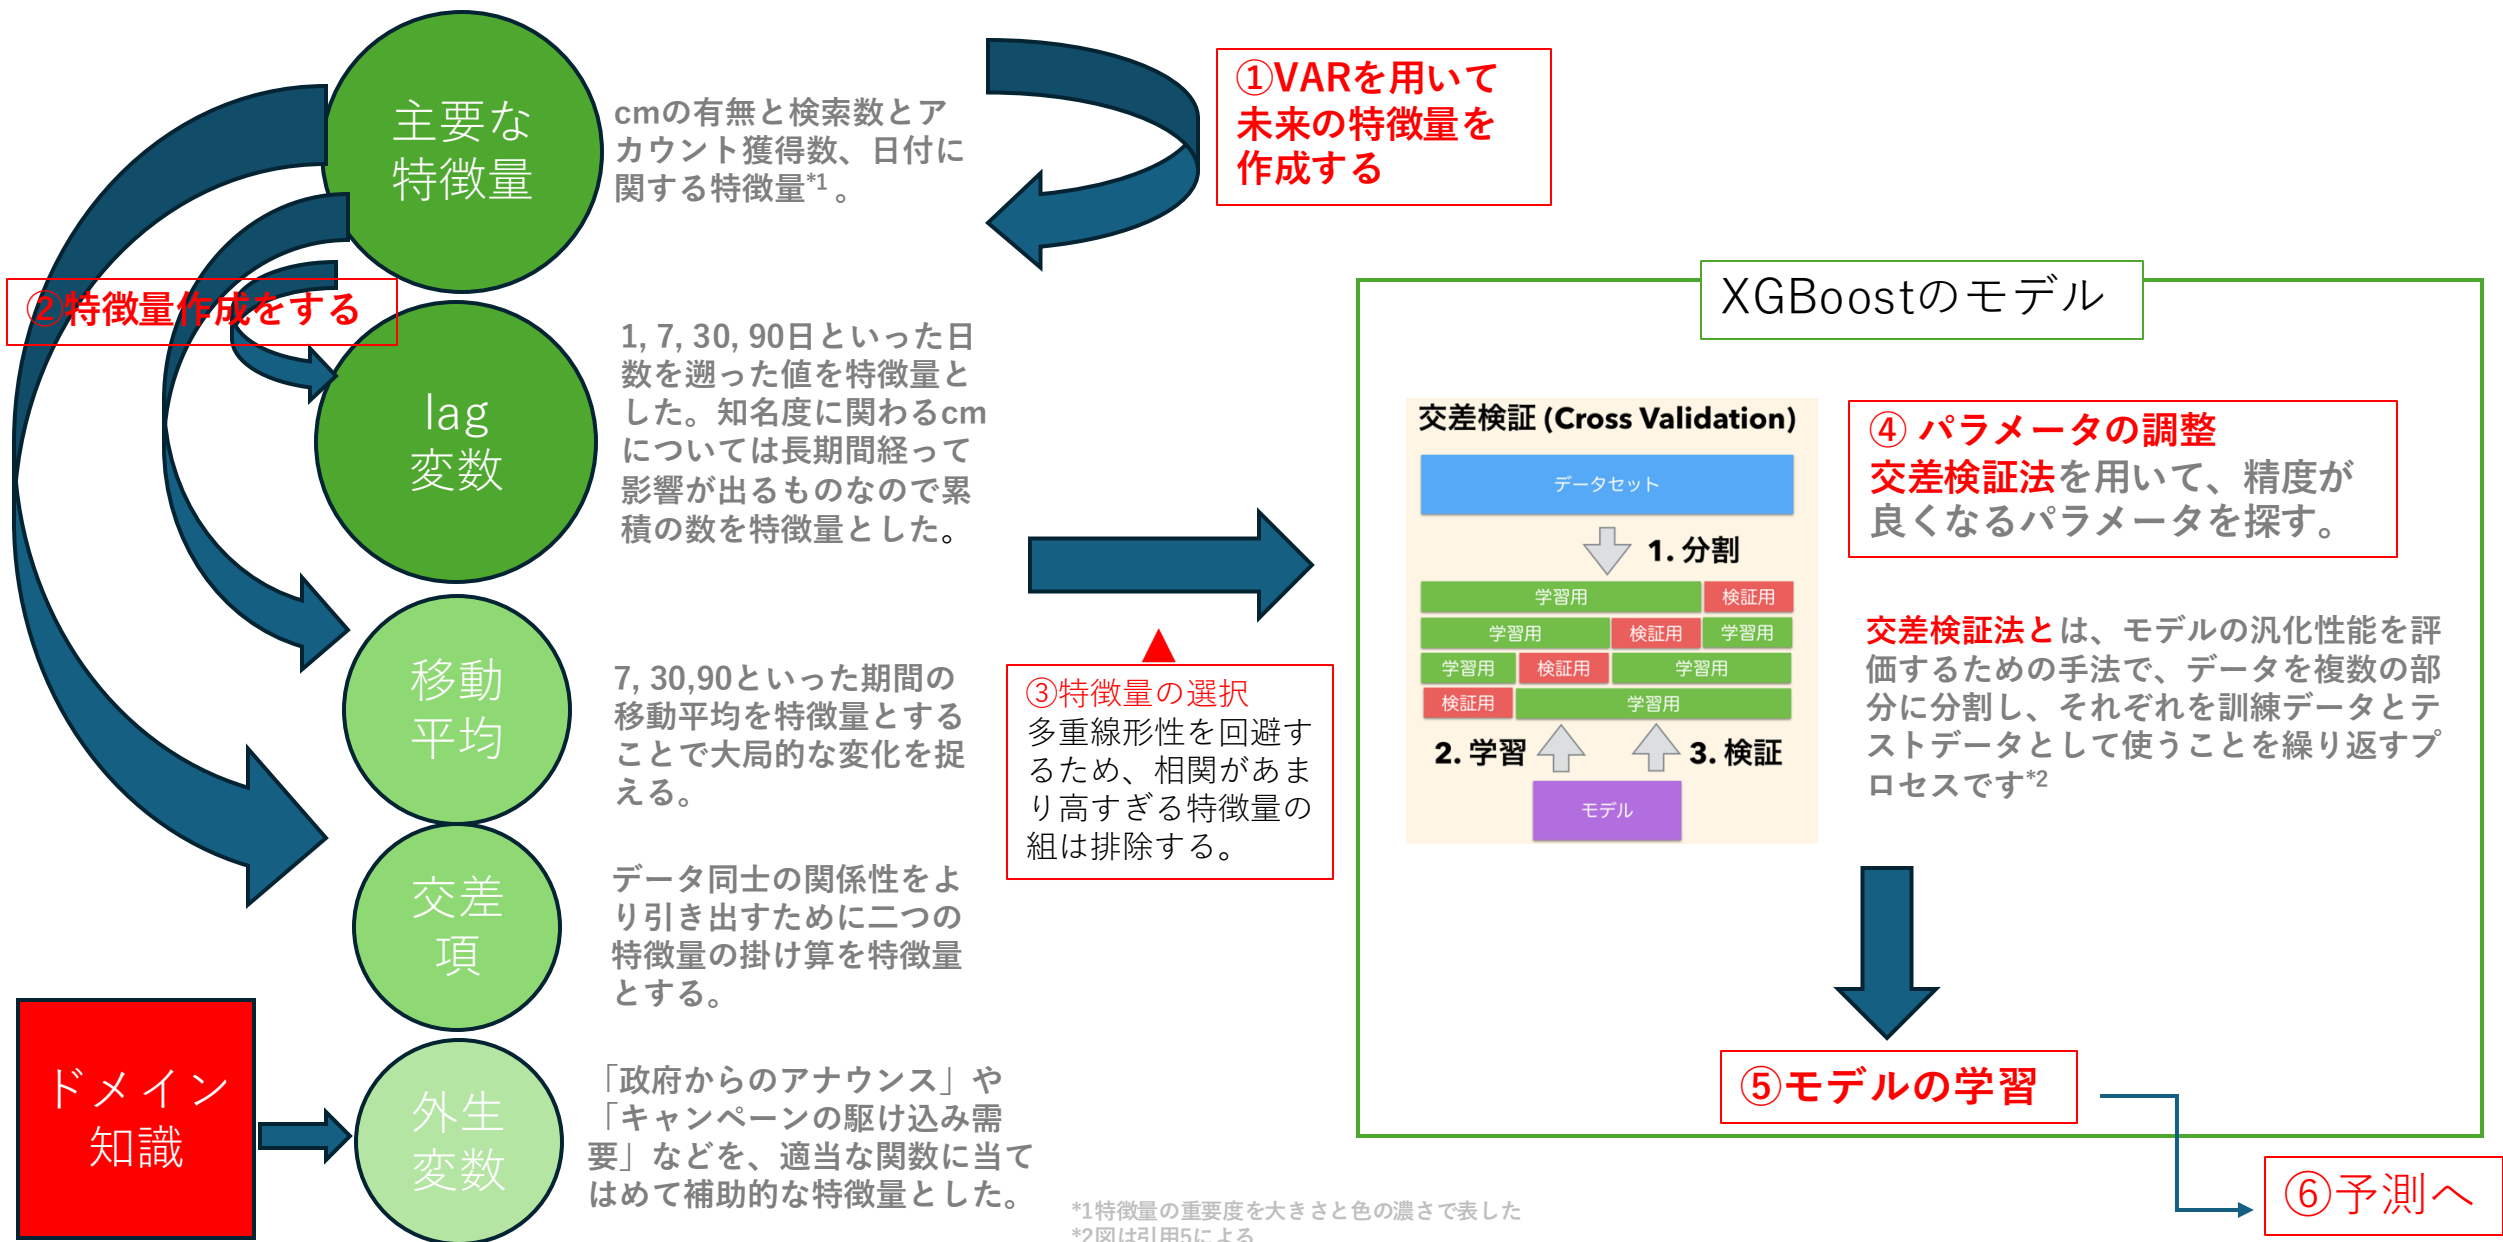


図7 VARのイメージ*4

*1引用6より
*2引用8より
*3引用12より
*4引用13より

モデルの説明 -特徴量からモデル構築編-



モデルの説明 -他モデルとの比較編-

- ▣時系列解析のナイーブな方法として、**ARIMA**があるが、長期間の予測では**非常に精度が悪く**、他の特徴量を取り入れることができない。
- ▣**RNN/LSTM(深層学習)**は高精度な将来の予測を出す。しかし、実行に**時間がかかる**こと、結果が**解釈しづらいこと**、**大量のデータ**が必要なことが前提であること等**欠点が多い**。
- ▣**Xgboost**のみだと**高精度に予測を出す**が、将来の予測ができない。
- ▣**VAR**のみだと、構造が統計的に明快であり、**高速で時系列予測ができる**。しかし、ドメイン知識や特徴量の捉えきれない関係をうまく予測に反映できない。

他のやり方との比較

モデル	長所	短所
VAR (統計モデル)	多変量の時系列データの相関を捉えるのが得意	線形モデルなので複雑な非線形パターンを学習できない
ARIMA (統計モデル)	時系列のトレンドや季節性を捉えるのが得意	多変量データの相関を扱いにくく、外部要因の影響を加味しにくい
RNN/LSTM (深層学習)	長期の時系列依存関係を学習可能	学習に大量のデータが必要、計算コストが高い、解釈が難しい
XGBoost (機械学習)	非線形な関係性を学習しやすい、特徴量の重要度を可視化できる	時系列の依存関係を明示的に捉えられない
VAR + XGBoost (ハイブリッド)	VARで時系列の関係を捉え、XGBoostで非線形要因を加味	組み合わせの最適化が必要

今回提案したVAR+XGBoostの良い点

- ・実務においてもこのモデルは、**実行時間が短く、良い精度で予測を出す***1。
- ・VARの因果推定やXGBoostの特徴量の重要度や精度など、**結果の解釈性や精度**が明快にわかる*2。
- ・問い合わせ、アカウント作成、検索はどれも顧客の動きとして密接に関わっており、VARはその相互関係を程よく捉えられる


*1予測するためのコードの実行時間は、データ量によるが15分程度であり、深層学習の場合30分程度かかる。

*2VARの因果推定には、Grangerの因果推定などがある。

機械学習モデルで予測する(1) -通常時-

2020-03-01から 2020-03-31(コロナ禍だが比較的數字が安定している)について、日付とcmの有無(会社の方針)以外の**特徴量がわからない**として、過去のデータから、一ヶ月間を予測した時の機械学習のモデルを作成した。モデルの分析と、実際の値と予測値の違いについて評価を行う。

特徴量重要度*1



機械学習モデルからの示唆

- dow(曜日)やwoy (週)といった日付の影響や、call_num(問い合わせの数)自体のlag変数の影響が多い。
- acc_get_cnt(アカウント獲得数)に関する特徴量の重要度も大きい(どちらもグラフの形が似ていたため当然であろう)
- cm_flg_90d(過去90日間にcmを出した日の累積)が重要度を持っているのは、cmが長期的に知名度に影響を与えていると考えれば納得がいく*2。
- search_cntのデータは日毎の上下の変動が激しく、特徴量としての影響がはっきり現れなかった。



*1lagはlag変数を指す。maは移動平均を指す。ma_ratioやma_diffは短期の移動平均の長期の移動平均の比や差を表す。

*2これはcmを出す人の意思決定(例えば売れる時にcmを出す)が影響するので一概に言えない。

機械学習モデルで予測する(2) -通常時-

■ 実際に2020-03-01から 2020-03-31について、日付とcmの有無以外に**特徴量がわからない**として、過去のデータから、一ヶ月間を予測した時の機械学習のモデルを作成した。モデルの分析と、実際の値と予測値の違いについて評価を行う(使用したデータは2018-06-01から2020-02-29までである)。

モデルの予測(VAR + Xgboost)



Actual(青)が実際の値、Predicted(オレンジ)が予測値*1

モデルの性能

MAE*2: 15.440096669860425,
RMSE*3: 20.965829777669445

(参考例)

ARIMAの場合

MAE: 54.11634986826634
RMSE: 59.858572780164785

(考察)

- 一ヶ月の予測であるため誤差はある程度生じた。また2019-10付近で急激に上がった影響で全体的に**大きめに表示された**。
- 結果、予測値と観測値が1日で平均15件ほど離れている。実用に足る予測値だ、

*1機械学習モデルでは土日祝日の問い合わせ回数を完全に0にすることはできなかったため、出力を土日祝日のみ0に直す変換をした。なお、モデルの性能はそれをしていない場合のモデル単体の性能を表示している。

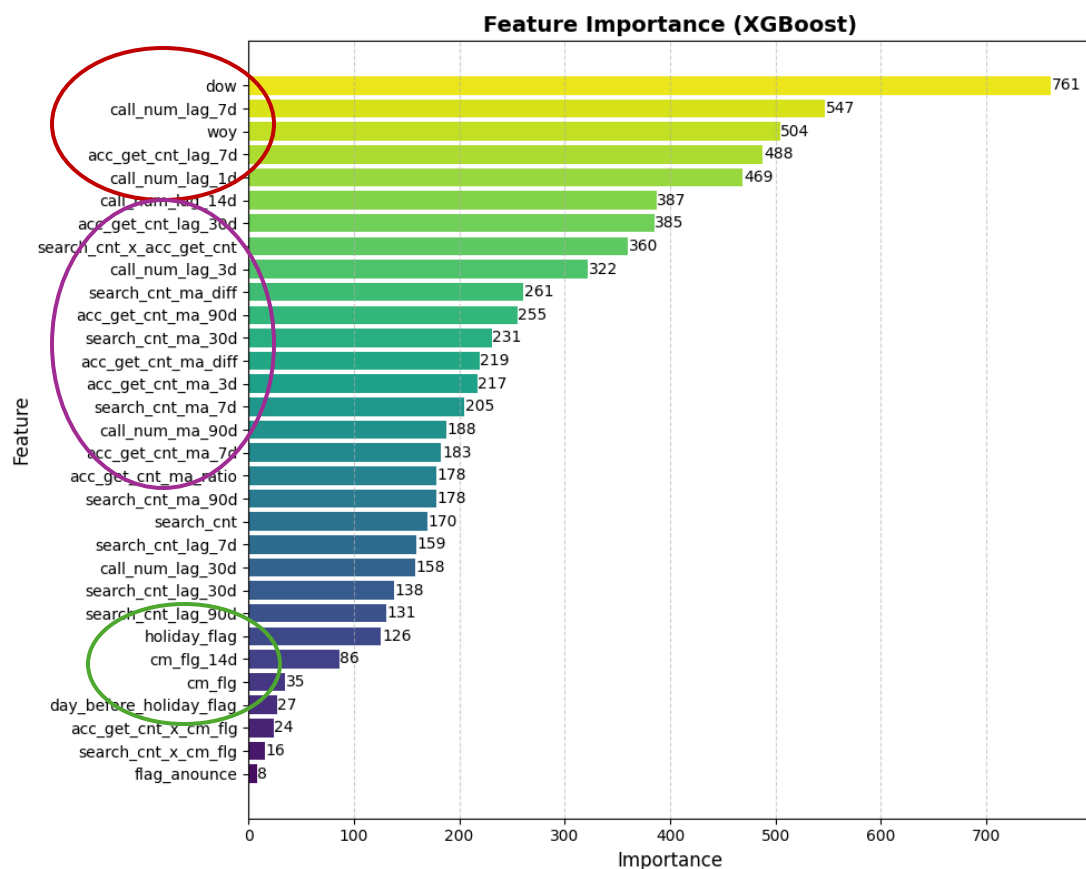
*2 MAEは観測値と実際の値の差の絶対値の平均である。正負が打ち消しあい、小さく表示されることがある。

*3 RMSEは、観測値と実際の値の差の二乗の平方根であり、観測値と実際の値の乖離を正確に評価する。

機械学習モデルで予測する(3) - ピーク時 -

■実際に2019-09-01から 2020-09-30について、日付とcmの有無以外に**特徴量がわからない**として、過去のデータから、一ヶ月間を予測した時の機械学習のモデルを作成した。モデルの分析と、実際の値と予測値の違いについて評価を行う(使用したデータは2018-06-01から2019-08-31までである)。

特徴量重要度*1



機械学習モデルからの示唆

- 使用したデータが短くなり、特徴量の重要度も少し変わったが、全体の傾向は先程と変わらない*2。
- **dow(曜日)**や**woy(週)**といった日付の影響や、**call_num**(問い合わせの数)自体のlag変数の影響が多い。
- **search_cnt**と**acc_get_cnt**の重要度が近づいている(データが少ないのが原因と考えられる)。
- **cm**の重要度が少なくなっている*3。

*1lagはlag変数を指す。maは移動平均を指す。ma_ratioやma_diffは短期の移動平均の長期の移動平均の比や差を表す。

*2特徴量の選択は毎行行っており、多重共線性を回避するために除去する関係で、特徴量は毎回異なる場合がある。

*3cmの重要度が低いのは、問い合わせの回数を予測する上で使いづらい特徴量であるという意味で、cm自体アカウント獲得数や検索数といった他の値に影響を与えていることに注意する。


機械学習モデルで予測する(4) -ピーク時-

■実際に2019-09-01から 2020-09-30について、日付とcmの有無以外に**特徴量がわからない**として、過去のデータから、一ヶ月間を予測した時の機械学習のモデルを作成した。モデルの分析と、実際の値と予測値の違いについて評価を行う(使用したデータは2018-06-01から2019-08-31までである)。

モデルの予測(VAR + Xgboost)



XGBoost Prediction vs. Actual



Actual(青)が実際の値、Predicted(オレンジ)が予測値 *1

*1機械学習モデルでは土日祝日の問い合わせ回数を完全に0にすることはできなかったため、出力を土日祝日のみ0に直す変換をした。なお、モデルの性能はそれをしていない場合のモデル単体の性能を表示している。

モデルの性能

全体の結果

MAE: 68.44356833299001,
RMSE: 111.3185353140558

(参考例)

ARIMAの場合

MAE: 219.04298250730616 RMSE:
265.8070828841246

[考察]

- レジ改修補助金キャンペーン終了の**駆け込み需要**については正しく評価しきれなかった(問い合わせの数は普段の2倍以上であった)。
- **そのほかの週の予測**はうまく近似できた。
- 結果、予測値と観測値の乖離の1日の平均が68件ほどである。最後の1週間に予測の2倍弱が観測されたことが原因である。

施策とその効果について(1)

提案事業

- コールセンターの労働力として一定数の正社員とパートタイムを雇う。
- 1ヶ月単位で問い合わせ数の予測を行い、予測値を元に必要な人員を計算しシフトを定める。
- これを実行することで、固定的なシフトよりもコストカットが見込める^{*1}。

試算結果

1. 現行体制（正社員5人＋パートタイマー5人の固定体制）
 1. 総コスト：約 2,500,000円
2. 改革後体制（正社員3人＋柔軟なパートタイム配置）
 1. 正社員コスト：約 750,000円
 2. パートタイマーコスト：約 600,000円
 3. 機会費用損失：約 540,000円
 4. 合計コスト：約 1,890,000円
3. 削減効果
 1. 現行体制と比較して削減額は
約 610,000円(図8参照)

^{*1} Airレジのコールセンター(現行体制)では労働力として正社員が半分以上登用され、経験則に基づいて人数が決められていると仮定した。現行体制では問い合わせ数の最大限に対応できる数の人員を常に配置していることになる。

^{*2} 引用7より


^{*3} 筆者作成

^{*4} 明確な根拠があるわけではない。ただ問い合わせを取り逃がすことに関するコストを削減効果に含めるための数値である。問い合わせが必ずしも定着につながるとは限らないため、多く見積もったと見るべきだろう。

試算のための前提条件

- **ピーク時の1ヶ月間(2019-09)**についての試算
- コールセンターの時給は、派遣社員で1500円と見積もる。また、正社員の月給は25万円である^{*2}。
- 一日8時間労働で計算。土日祝日は勤務なし。
- 1件あたりの対応時間は10分とする。
- 予測の不確かさを反映するため(予測値)×1.1(多めに見積もる)を実際の予測値として扱う。
- 問い合わせに応じることができなかった場合機会費用の損失を10000円^{*4}として計算する。
- 現行体制：正社員5人＋パートタイマー5人の経験則に基づく体制^{*1}
- 改革後の体制：正社員3人としパートタイマーを予測値に基づいて調達する体制

図8 削減の試算(ピーク時)^{*3}



施策とその効果について(2)

試算のための前提条件


試算のための前提条件を変更し、通常時も求める。

- **通常時の1ヶ月間(2020-03)**についての試算
- 現行体制：正社員3人＋パートタイマー1人の体制(経験則で固定)
- 改革後の体制：正社員2人としパートタイマーを予測値に基づいて調達する体制
- 他の条件は同じ

試算結果

- 1, 現行体制（正社員3人＋柔軟パートタイム1人）
総コスト：約 1,050,000円
- 2, 改革後体制（正社員2人＋柔軟なパートタイマー配置）
1, 正社員コスト：約 700,000円、2, パートタイムコスト：約 300,000円、3, 機会費用損失：**0円**、4, 合計コスト：約 1,000,000円
- 3, 削減効果
削減額：約 50,000円(図9参照)

図9 削減の試算(通常時)*2



提案のまとめと拡張性について

- 今回のコンサルティングでは、定着率の悪化の原因は顧客への対応にあるとして、問い合わせの対応の改善策を出した。
- その改善策ではVARとXGBoostを用いて実務に有用な程度の速さと精度を保証しながら問い合わせの回数を予測し、パートタイムと正社員を組み合わせで*1人員の最適化を図った。
- 削減の試算は、通常月では5万円ほど、繁忙期の9、10月では60万円程だ（機会損失を10000円とした場合）。
- しかし、この**試算は過小評価している**側面がある。1時間あたりのデータがあれば、より詳細な試算を計算できる。
- **提案の趣旨**は、VAR+XGBoostの機械学習モデルという方法を用いて曜日やtrendなどを考慮すれば、必要な人数を適当な精度で求めることができる事あった。
- 提案したモデルでは、1日単位ではなく、1時間単位の問い合わせ数のデータであった場合は、より細かいシフト調整に応用可能である。
- また、シフトが1ヶ月単位ではなく、もっと短期間(2週間)で動かせる場合はより高い精度が望める。
- 今回はこのモデルと事業提案で一つのコンサルとしたい。

*1パートによって対応の品質が落ちるという批判は的を得ていないように感じる。実際、マニュアルの作成や正社員の常備によって現場で解決すると考えて提案をした。

*2筆者作成

お見積もり

提案させていただいた施策を実行することで1年間に約200万円ほどの利益が見込まれる。競争が激化する無料タブレットPOS業界において、先端技術である機械学習モデルを導入し顧客のリテンションを向上させていくことは、Airレジの競争力向上につながる。施策の将来的な収益を踏まえ、お見積りを以下のように提案する。

30万円

コンサルティング費用

4万円/月

機械学習モデルの
構築・メンテナンス

参考文献

本資料を作成するにあたって使用した参考文献一覧

- 1, 矢野経済研究所. (2018). *日本マーケットシェア事典 2018年版*. 矢野経済研究所.
- 2, リクルートライフスタイル. (2018年8月23日). 利用店舗数No.1の無料POSレジアプリ『Airレジ』を運営するリクルートライフスタイルと、全国62万店舗の加盟店を持つUSENが中小企業の労働生産性向上およびIT化を促進. リクルートニュースルーム.
https://www.recruit.co.jp/newsroom/recruit-lifestyle/news/business/nw26626_20180823
- 3, saas-search.jp. (2021). 人気POSシステム比較. *Saas Search*. <https://saas-search.jp/saas-services/pos-system/popular-pos/>
- 4, Jasper. (2021). スマレジに関する比較記事. *Jasper*. <https://jasper.tokyo/sumareji-comparison/>
- 5, matsukura04583. (2019). 「ホールドアウト法」と「交差検証法」の違い. *Qiita*.
<https://qiita.com/matsukura04583/items/042fcbf1bc594dfca7a4>
- 6, 馬場, 真哉. (2020). *時系列分析と状態空間モデルの基礎 RとStanで学ぶ理論と実装*. 朝倉書店.
- 7, 求人ボックス. (2023). コールセンターの時給分析. 求人ボックス. <https://xn--pckua2a7gp15o89zb.com/%E3%82%B3%E3%83%BC%E3%83%AB%E3%82%BB%E3%83%B3%E3%82%BF%E3%83%BC%E3%81%AE%E5%B9%B4%E5%8F%8E%E3%83%BB%E6%99%82%E7%B5%A6>
- 8, Esri Japan. (2021). XGBoostの仕組み解説. *ArcGIS Pro ヘルプ*. <https://pro.arcgis.com/ja/pro-app/3.3/tool-reference/geoai/how-xgboost-works.htm>
- 9, 日本経済新聞. (2018年8月23日). リクルート、レジアプリをUSENにOEM、音楽配信なども販促. *日本経済新聞*.
- 10, ニールセン デジタル株式会社. (2022). 飲食店予約サイト利用者、前年から増加傾向にーホットペッパーグルメ、食べログ、ぐるなびの比較. 口コミ活用アカデミー. Retrieved from https://academy.kutikomi.com/news/restaurant_gourmetsite_users/
- 11, WWD JAPAN. (2017). リクルート、ビューティ予約件数が前年度から440万件増加. WWD JAPAN. Retrieved from <https://www.wwdjapan.com/articles/461116>
- 12, Yao, X., Fu, X., & Zong, C. (2022). *Short-Term Load Forecasting Method Based on Feature Preference Strategy and LightGBM-XGboost*. ResearchGate. https://www.researchgate.net/figure/Schematic-illustration-of-the-XGboost-model_fig2_362100649
- 13, 藤丸. (2023年5月17日). 【例題で解説】VAR分析. Staat. https://corvus-window.com/app_var/